


POSE DETECTION




EQUIPE:
TAILAN DE SOUZA
PEDRO ARTHUR
FRANCISCO DJALMA

O QUE É POSE DETECTION?

A Detecção de Pose Humana é a técnica de Visão Computacional que visa identificar e localizar pontos anatômicos e articulações do corpo humano em imagens ou vídeos. Esses pontos, conhecidos como *keypoints* ou *landmarks*, incluem partes específicas como nariz, olhos, orelhas, ombros, cotovelos, punhos, quadris, joelhos e tornozelos. Ao conectar esses pontos através de arestas predefinidas, o modelo gera uma representação visual estruturada um esqueleto virtual que capta com precisão a postura e o movimento da pessoa na imagem.





Landmarks

- | | |
|--------------------|----------------------|
| 0. Nose | 17. Left_pinky |
| 1. Left_eye_inner | 18. Right_pinky |
| 2. Left_eye | 19. Left_index |
| 3. Left_eye_outer | 20. Right_index |
| 4. Right_eye_inner | 21. Left_thumb |
| 5. Right_eye | 22. Right_thumb |
| 6. Right_eye_outer | 23. Left_hip |
| 7. Left_ear | 24. Right_hip |
| 8. Right_ear | 25. Left_knee |
| 9. Left_mouth | 26. Right_knee |
| 10. Right_mouth | 27. Left_ankle |
| 11. Left_shoulder | 28. Right_ankle |
| 12. Right_shoulder | 29. Left_heel |
| 13. Left_elbow | 30. Right_heel |
| 14. Right_elbow | 31. Left_foot_index |
| 15. Left_wrist | 32. Right_foot_index |
| 16. Right_wrist | |

POR QUE ISSO É IMPORTANTE?

A principal vantagem da estimativa de pose é revelar como o sujeito está posicionado e se movendo, sem a necessidade de sensores físicos ou roupas especiais com marcadores. Suas aplicações abrangem diversos setores do mundo real

01

Monitoramento de exercícios e Fisioterapia


02

Análise Esportiva avaliação da biomecânica de atletas quadro a quadro, auxiliando no *feedback* de treinadores

03

Sistemas de Segurança

POSE DETECTION PARA AJUDA NO EXERCÍCIO DE AGACHAMENTO



EVOLUÇÃO HISTÓRICA (DÉCADAS DE 80, 90 E 2000)

1980 e 1990

O rastreamento de movimentos dependia fortemente de equipamentos especializados. Na indústria de animação e cinema, atores usavam roupas cobertas por marcadores reflexivos em ambientes de estúdio totalmente controlados. Esses sistemas de captura de movimento (MoCap) eram extremamente precisos, porém caros e nada acessíveis.

Anos 2000

No início e meados dos anos 2000, a detecção de pose dependia de modelos gráficos e extração manual de características. Os sistemas calculavam a postura identificando contornos e segmentos corporais em imagens 2D usando algoritmos de silhueta. O grande divisor de águas da década ocorreu em 2010 com o lançamento do Microsoft Kinect.

Microsoft's Kinect for Xbox 360



<https://www.hollywoodreporter.com/business/digital/microsoft-s-kinect-xbox-360-165990/>

EVOLUÇÃO HISTÓRICA 2014 E 2017

2014

O DeepPose é considerado o marco inicial que aplicou Deep Learning à área, o trabalho de Toshev e Szegedy demonstrou que as Redes Neurais Convolucionais (CNNs) eram capazes de estimar posições corporais diretamente das imagens com alta precisão

2017

O OpenPose é Desenvolvido por pesquisadores da Carnegie Mellon University, o OpenPose revolucionou a visão computacional ao se tornar o primeiro sistema de código aberto capaz de estimar a pose de múltiplas pessoas em tempo real. Ele eliminou a necessidade de cenários controlados, rastreando esqueletos precisos através de câmeras de vídeo comuns

EVOLUÇÃO HISTÓRICA ATUALMENTE



Atualmente

Os modelos atuais amadureceram consideravelmente e resolvem gargalos de processamento com abordagens inovadoras e de baixo custo computacional. O MediaPipe Pose é focado em inferência leve *on-device*, capaz de rastrear 33 pontos em celulares e navegadores de internet. Modelos baseados na arquitetura *YOLO*, como o moderno *YOLO26-Pose*, realizam detecção e rastreamento de altíssima velocidade em dispositivos processando múltiplas pessoas simultaneamente em tempo real

CONCEITOS IMPORTANTES

1. **Keypoints / Landmarks:** marcos anatômicos que a máquina aprende a identificar com coordenadas exatas, com uma pontuação de confiança associada.
2. **Esqueleto corporal:** conjunto de conexões desenhadas entre os *keypoints* baseadas na estrutura humana pré-definida pelo *dataset*.
3. **Pose Estimation 2D vs 3D:** A estimativa 2D prevê locais em coordenadas da imagem (X, Y), enquanto a 3D estima também a profundidade (X, Y, Z), inferindo um espaço virtual tridimensional.
4. **Pose Tracking:** capacidade de acompanhar essas coordenadas continuamente de forma suave ao longo de quadros em um fluxo de vídeo.

PIPELINE GERAL DE INFERÊNCIA



PRÉ-PROCESSAMENTO

- 01 Redimensionamento e Letterbox Padding
- 02 Normalização e Conversão de Cor
- 03 Formatação de Tensores [N,C,H,W]



ENGENHARIA DE OTIMIZAÇÃO NO PRÉ-PROCESSAMENTO

01

Aceleração via Hardware (GPU): Mover o tensor da imagem imediatamente para a memória da GPU para executar o padding e a normalização de forma acelerada

02

Memória Contígua: Garante que os blocos de memória da imagem sejam armazenados sequencialmente em um único bloco de memória, o que permite que a GPU e motores avançados de inferência leiam os dados subjacentes com latência de acesso de memória quase nula. Ex: `.contiguos()`

INFERÊNCIA


Estratégias de Detecção


1. Top-Down

- a. Bounding Boxes
- b. Keypoints/Articulações

2. Bottom-Up

- a. Heatmap
- b. Campos de Afinidade de Partes (PAFs)





PRINCIPAIS ARQUITETURAS

O desenvolvimento atual foca em solucionar um dilema constante: equilibrar a **máxima precisão de localização** com a **velocidade de inferência (latência)** necessária para aplicações em tempo real.

YOLO

MediaPipe

RTMPose

ViTPose

PÓS-PROCESSAMENTO: LIMPEZA

01

Restauração de Escala: Pega as coordenadas dos tensores e as estica de volta para o tamanho e proporção exatos do vídeo em alta resolução.

02

Limiar de Confiança: Descarta qualquer palpite em que a IA tenha baixa probabilidade de acerto.

03

Supressão de Não-Máximos (NMS): O modelo costuma gerar várias esqueletos sobrepostos em cima da mesma pessoa por excesso de zelo. O NMS apaga todas as duplicatas, **preservando apenas a de maior pontuação.**

PÓS-PROCESSAMENTO: ESTABILIZAÇÃO

01

Média Móvel (SMA): Suaviza o movimento analisando a média de posição dos últimos quadros (frames).

02

Filtro 1 Euro (1€ Filter): É um filtro inteligente que aplica uma "frenagem pesada" para matar o tremor quando a pessoa está parada, mas desliga o filtro instantaneamente quando a pessoa se move rápido, evitando que o esqueleto fique com lag (atraso).

SAÍDA E MÉTRICAS

FORMATO DE SAÍDA

- **Vetorização [x, y, v]:** Cada articulação possui coordenadas e um sinalizador de visibilidade (v), onde:
 - 0 = Fora da tela;
 - 1 = Ocluído (escondido, mas o modelo deduziu a posição);
 - 2 = Visível.
- **Saída YOLO:** Entrega a caixa delimitadora da pessoa e as coordenadas da pose em pixels (brutos e normalizados).
- **Saída MediaPipe:** Entrega coordenadas 2D e um mapa 3D [x, y, z] em metros, utilizando o centro do quadril humano como o ponto de origem espacial (0,0,0).

SAÍDA E MÉTRICAS

MÉTRICAS DE AVALIAÇÃO

- **OKS (Object Keypoint Similarity):** Mede a distância entre a previsão do modelo e o gabarito real. O OKS é inteligente, pois sabe que é mais fácil acertar a ponta do nariz do que encontrar o centro exato de um quadril, aplicando pesos diferentes por articulação.
- **mAP (Mean Average Precision):** Baseada no OKS, é a nota de precisão geral do modelo. Inclui subdivisões (AP-M e AP-L) para avaliar se o modelo acerta pessoas pequenas/médias no fundo ou apenas pessoas grandes perto da câmera.
- **PCK (Percentage of Correct Keypoints):** Considera a junta "correta" se cair dentro de um limite de distância. Geralmente usa o tamanho da cabeça do próprio usuário como "régua" de tolerância (PCKh).